

عنوان پروژه: سامانه کرالر و مدیریت آگهی‌های املاک شمال ایران

هدف تسک: یک سامانه بک‌اند طراحی و پیاده‌سازی کنید که آگهی‌های مربوط به املاک و زمین در استان‌های شمالی ایران را از منابع آنلاین دریافت، نرمال‌سازی، ذخیره و در قالب API قابل جست‌وجو ارائه کند.

محدوده جغرافیایی اصلی سامانه شامل این استان‌هاست:

- مازندران
- گیلان
- گلستان

سامانه باید بتواند آگهی‌های مرتبط با موارد زیر را مدیریت کند:

- آپارتمان
- خانه
- ویلا
- زمین
- باغ
- خانه روستایی
- مغازه و ملک تجاری
- سایر املاک قابل خرید، فروش یا اجاره

تمرکز اصلی ارزیابی روی طراحی معماری، پردازش پس‌زمینه، مدیریت داده‌های تکراری، تحمل خطا، محدودسازی درخواست‌ها، قابلیت استقرار و کیفیت تست‌هاست؛ نه صرفاً استخراج HTML

منابع پیشنهادی برای اجرای کرالر عبارت‌اند از:

- دیوار
- شیپور
- وبسایت‌های تخصصی و بومی املاک
- سایر منابع عمومی با رعایت محدودیت‌های آن‌ها

استفاده از هر منبع باید مطابق شرایط استفاده، محدودیت‌های فنی و سیاست‌های انتشار همان منبع انجام شود.

الزامات این بخش

- در README باید منابع بررسی‌شده، محدودیت‌های دسترسی و تصمیم معماری مربوط به هر منبع توضیح داده شود.
- الزامی است معماری به‌گونه‌ای طراحی شود که افزودن و مدیریت چند منبع مختلف امکان‌پذیر باشد.

تکنولوژی‌های الزامی

- Python
- Django
- PostgreSQL
- Git

انتخاب کتابخانه HTTP ، parser، ابزار لاگ و سایر وابستگی‌ها آزاد است؛ اما دلایل انتخاب‌های مهم باید در README توضیح داده شود.

سناریوی اصلی سامانه

کاربر یا اپراتور سامانه باید بتواند:

۱. یک منبع کرال را انتخاب کند.
۲. محدوده جغرافیایی را مشخص کند.
۳. نوع معامله را مشخص کند:
 - خرید
 - فروش
 - اجاره
۴. نوع ملک را مشخص کند:
 - آپارتمان
 - ویلا
 - زمین
 - باغ
 - خانه
 - تجاری
 - سایر
۵. شهر یا منطقه هدف را انتخاب کند.
۶. یک job کرال ثبت کند
۷. وضعیت job را مشاهده کند.
۸. آگهی‌های نرمال شده را جست‌وجو و فیلتر کند
۹. اجرای مجدد کرال را بدون ایجاد داده‌های تکراری انجام دهد.
۱۰. در صورت حذف یا غیرفعال شدن آگهی در منبع، وضعیت آن را مدیریت کند.

محدوده جغرافیایی

فهرست شهرها نباید به صورت محدود و **hardcode** شده در منطق کرال پیاده‌سازی شود. امکان افزودن شهر و منطقه جدید باید در طراحی پیش‌بینی شود.

موارد زیر الزامی است:

- timeout مشخص برای درخواست‌ها
- retry محدود برای خطاهای موقت شبکه و خطاهای ۵xx
- مدیریت ۴۲۹ Too Many Requests
- رعایت 'Retry-After' در صورت وجود
- exponential backoff
- جلوگیری از retry بی‌نهایت
- عدم retry خودکار برای خطاهای دائمی مانند ۴۰۱، ۴۰۳ یا ۴۰۴، مگر با منطق مشخص و مستند

جلوگیری از داده‌های تکراری

یک آگهی ممکن است:

- در اجرای مجدد همان منبع دوباره دیده شود.
- با چند صفحه یا فیلتر مختلف دریافت شود.
- در دو منبع مختلف با اطلاعات مشابه ظاهر شود.
- URL یا عنوان متفاوت اما محتوای مشابه داشته باشد.

هدف، ساخت یک سامانه کامل تجاری نیست؛ هدف ارزیابی توانایی طراحی و پیاده‌سازی یک راهکار بک‌اند قابل اجرا، قابل توسعه، مقاوم در برابر خطا و قابل دفاع از نظر معماری است.